Московский государственный технический университет им. Н.Э. Баумана
Кафедра «Системы обработки информации и управления»

Лабораторная работа 6
по дисциплине
«Методы машинного обучения»
на тему
«Ансамбли моделей машинного обучения.»

Выполнил:
студент группы ИУ5-21М
Тодосиев Н. Д.

Москва — 2019 г.

1. Описание задания

Цель лабораторной работы: изучение ансамблей моделей машинного обучения.

2. Задание

1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
4. Обучите две ансамблевые модели. Оцените качество моделей с помощью одной из подходящих для задачи метрик. Сравните качество полученных моделей.
5. Произведите для каждой модели подбор значений одного гиперпараметра. В зависимости от используемой библиотеки можно применять функцию GridSearchCV, использовать перебор параметров в цикле, или использовать другие методы.
6. Повторите пункт 4 для найденных оптимальных значений гиперпараметров. Сравните качество полученных моделей с качеством моделей, полученных в пункте 4.

3. Ход выполнения лабораторной работы

3.1. Выбор датасета

В качестве исходных данных выбираем датасет о террористических атаках. Он содержит около 180 тысячи записей, а также имеет разные столбцы с категориальными данными. Такой датасет может подходить для обучения методом ближайших соседей.

В качестве задачи поставим определение вида атаки по остальным колонкам.

3.2. Проверка и удаление пропусков

In [0]:
```
import warnings
warnings.filterwarnings('ignore')
```

In [4]:
```
!pip install git+git://github.com/kvoyager/GmdhPy.git
```

```
Collecting git+git://github.com/kvoyager/GmdhPy.git
  Cloning git://github.com/kvoyager/GmdhPy.git to /tmp/pip-req-build-h3m6u23s
Requirement already satisfied (use --upgrade to upgrade): GmdhPy==2.0 from git+git://github.c
Requirement already satisfied: numpy in /usr/local/lib/python3.6/dist-packages (from GmdhPy=
Requirement already satisfied: six in /usr/local/lib/python3.6/dist-packages (from GmdhPy==2.
Requirement already satisfied: scikit-learn in /usr/local/lib/python3.6/dist-packages (from Gmdh
Requirement already satisfied: pandas in /usr/local/lib/python3.6/dist-packages (from GmdhPy=
Requirement already satisfied: scipy>=0.13.3 in /usr/local/lib/python3.6/dist-packages (from sci
Requirement already satisfied: pytz>=2011k in /usr/local/lib/python3.6/dist-packages (from pan
Requirement already satisfied: python-dateutil>=2.5.0 in /usr/local/lib/python3.6/dist-packages
Building wheels for collected packages: GmdhPy
  Building wheel for GmdhPy (setup.py) ... done
```

Stored in directory: /tmp/pip-ephem-wheel-cache-hp547vc8/wheels/69/6c/43/d6d9c8729bf1a2d
Successfully built GmdhPy

In [5]:
```
from google.colab import drive, files
drive.mount('/content/drive')
```

Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/con

In [0]:
```
from google.colab import files
import os
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
os.listdir()
data = pd.read_csv('drive/My Drive/Files/globalterrorismdb_0718dist.csv',
                   sep=",", encoding="iso-8859-1")
```

Количество пустых колонок огромно, поэтому сначала удалим все столбцы, у которых количество заполненных значений менее 150000 (примерно 5/6 от всего датасета), а затем удалим строки с пустым значением.

In [7]:
```
# Удаление колонок, содержащих пустые значения
data_temp_1 = data.dropna(axis=1, how='any', thresh=150000)
(data.shape, data_temp_1.shape)
```

Out[7]: ((181691, 135), (181691, 47))

In [8]:
```
data_new_1 = data_temp_1.dropna(axis=0, how='any')
(data_temp_1.shape, data_new_1.shape)
```

Out[8]: ((181691, 47), (134042, 47))

In [9]:
```
data_new_1.head()
```

Out[9]:

	eventid	iyear	imonth	iday	extended	country	country_txt	\
5	197001010002	1970	1	1	0	217	United States	
6	197001020001	1970	1	2	0	218	Uruguay	
7	197001020002	1970	1	2	0	217	United States	
8	197001020003	1970	1	2	0	217	United States	
9	197001030001	1970	1	3	0	217	United States	

	region	region_txt	provstate	...	weapsubtype1_txt	\
5	1	North America	Illinois	...	Unknown Gun Type	
6	3	South America	Montevideo	...	Automatic or Semi-Automatic Rifle	
7	1	North America	California	...	Unknown Explosive Type	
8	1	North America	Wisconsin	...	Molotov Cocktail/Petrol Bomb	
9	1	North America	Wisconsin	...	Gasoline or Alcohol	

```
   nkill  nwound  property  ishostkid       dbsource  INT_LOG  INT_IDEO  \
5    0.0     0.0         1        0.0  Hewitt Project       -9        -9
6    0.0     0.0         0        0.0           PGIS        0         0
7    0.0     0.0         1        0.0  Hewitt Project       -9        -9
8    0.0     0.0         1        0.0  Hewitt Project        0         0
9    0.0     0.0         1        0.0  Hewitt Project        0         0

   INT_MISC  INT_ANY
5         0       -9
6         0        0
7         0       -9
8         0        0
9         0        0

[5 rows x 47 columns]
```

```
In [10]: data2 = data_new_1.drop(["provstate", "eventid",
                                 "dbsource", "INT_LOG", "INT_IDEO", "INT_MISC",
                                 "INT_ANY", "individual", "weapsubtype1",
                                 "weapsubtype1_txt", "property", "vicinity", "crit2",
                                 "crit3", "natlty1", "iday", "imonth", "iyear",
                                 "extended"], axis=1)
         data2.shape

Out[10]: (134042, 28)
```

3.3. train_test_split

```
In [0]: from sklearn.model_selection import train_test_split
        attacktype = data2["attacktype1"]
        data3 = data2.drop(["attacktype1"], axis=1)
        for col in data3.columns:
          dt = str(data[col].dtype)
          if not (dt=='float64' or dt=='int64'):
            data3 = data3.drop([col], axis=1)
        data_X_train, data_X_test, data_y_train, data_y_test = train_test_split(
            data3, attacktype, test_size=0.2, random_state=1)
```

3.4. Обучение

```
In [0]: from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier

        from sklearn.metrics import mean_squared_error

In [0]: template = "Отклонение на тренируемой выборке: {:.3f} \
        отклонение на тестовой выборке: {:.3f}"

In [0]: class Classifier():
          def __init__(self, method, x_train, y_train, x_test, y_test):
            self._method = method
            self.x_train = x_train
```

```
        self.y_train = y_train
        self.x_test = x_test
        self.y_test = y_test
        self.target_1 = []
        self.target_2 = []

    def training(self):
        self._method.fit(self.x_train, self.y_train)
        self.target_1 = self._method.predict(self.x_train)
        self.target_2 = self._method.predict(self.x_test)

    def result(self, metric):
        print(template.format(metric(self.y_train, self.target_1),
                              metric(self.y_test, self.target_2)))
```

3.4.1. RandomForestClassifier

```
In [57]: rfr = Classifier(RandomForestClassifier(max_features=1), data_X_train,
                          data_y_train, data_X_test, data_y_test)
         rfr.training()
         rfr.result(mean_squared_error)
```

Отклонение на тренируемой выборке: 0.062 отклонение на тестовой выборке: 0.635

3.4.2. GradientBoostingClassifier

```
In [58]: gbc = Classifier(GradientBoostingClassifier(max_features=1), data_X_train,
                          data_y_train, data_X_test, data_y_test)
         gbc.training()
         gbc.result(mean_squared_error)
```

Отклонение на тренируемой выборке: 0.689 отклонение на тестовой выборке: 0.701

Видно, что на тестовой выборке обе ансамблевые модели ведут себя почти одинаково.

3.5. Подбор гиперпараметра K с использованием GridSearchCV и кросс-валидации

3.5.1. RandomForestClassifier

```
In [35]: n_range = np.array(range(3,10,1))
         tuned_parameters = [{'max_features': n_range}]
         tuned_parameters
```

```
Out[35]: [{'max_features': array([3, 4, 5, 6, 7, 8, 9])}]
```

```
In [37]: from sklearn.model_selection import GridSearchCV

         cl_rfc_gs = GridSearchCV(RandomForestClassifier(), tuned_parameters, cv=5,
                                  scoring='accuracy')
         cl_rfc_gs.fit(data_X_train, data_y_train)
```

```
Out[37]: GridSearchCV(cv=5, error_score='raise-deprecating',
             estimator=RandomForestClassifier(bootstrap=True, class_weight=None, criterion='g
                 max_depth=None, max_features='auto', max_leaf_nodes=None,
                 min_impurity_decrease=0.0, min_impurity_split=None,
                 min_samples_leaf=1, min_samples_split=2,
                 min_weight_fraction_leaf=0.0, n_estimators='warn', n_jobs=None,
                 oob_score=False, random_state=None, verbose=0,
                 warm_start=False),
             fit_params=None, iid='warn', n_jobs=None,
             param_grid=[{'max_features': array([3, 4, 5, 6, 7, 8, 9])}],
             pre_dispatch='2*n_jobs', refit=True, return_train_score='warn',
             scoring='accuracy', verbose=0)

In [38]: cl_rfc_gs.best_params_

Out[38]: {'max_features': 6}

In [39]: plt.plot(n_range, cl_rfc_gs.cv_results_['mean_test_score'])

Out[39]: [<matplotlib.lines.Line2D at 0x7fca60ecfac8>]
```

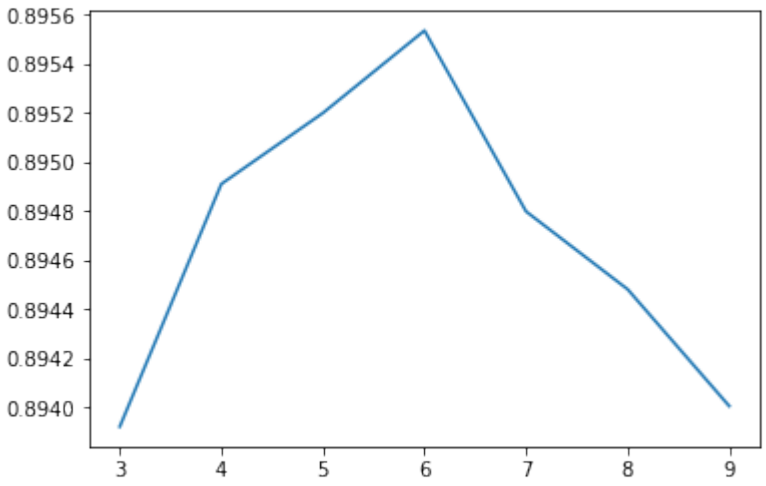

Как и говорит теория, *dl* примерно равно $\sqrt{D}$

3.5.2. GradientBoostingClassifier

```
In [43]: n_range = np.array(range(4,9,1))
         tuned_parameters = [{'max_features': n_range}]
         tuned_parameters

Out[43]: [{'max_features': array([4, 5, 6, 7, 8])}]

In [44]: cl_gbc_gs = GridSearchCV(GradientBoostingClassifier(), tuned_parameters, cv=3,
                               scoring='accuracy')
         cl_gbc_gs.fit(data_X_train, data_y_train)
```

```
Out[44]: GridSearchCV(cv=3, error_score='raise-deprecating',
             estimator=GradientBoostingClassifier(criterion='friedman_mse', init=None,
                   learning_rate=0.1, loss='deviance', max_depth=3,
                   max_features=None, max_leaf_nodes=None,
                   min_impurity_decrease=0.0, min_impurity_split=None,
                   min_samples_leaf=1, min_sampl...      subsample=1.0, tol=0.0001, validation_
                   verbose=0, warm_start=False),
             fit_params=None, iid='warn', n_jobs=None,
             param_grid=[{'max_features': array([4, 5, 6, 7, 8])}],
             pre_dispatch='2*n_jobs', refit=True, return_train_score='warn',
             scoring='accuracy', verbose=0)
```

```
In [45]: cl_gbc_gs.best_params_
```

```
Out[45]: {'max_features': 8}
```

```
In [46]: plt.plot(n_range, cl_gbc_gs.cv_results_['mean_test_score'])
```

```
Out[46]: [<matplotlib.lines.Line2D at 0x7fca63bf00f0>]
```

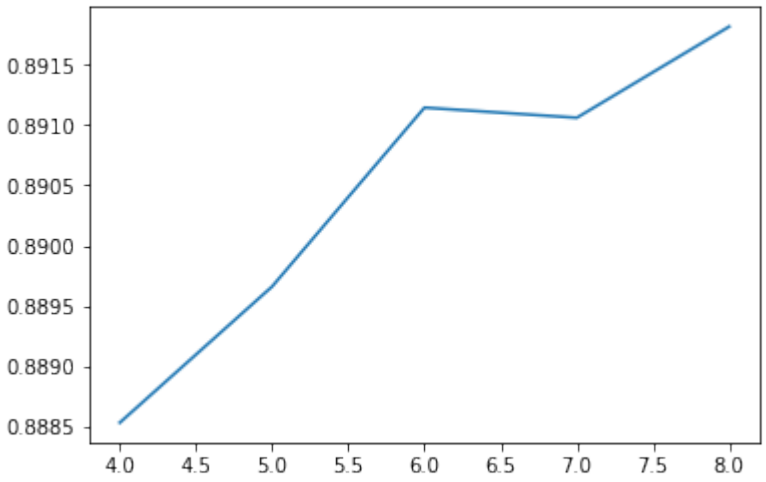

3.6. Сравнение модели с произвольным и лучшим параметром K

```
In [56]: rfr2 = Classifier(RandomForestClassifier(max_features=6), data_X_train,
                           data_y_train, data_X_test, data_y_test)
         rfr2.training()
         rfr2.result(mean_squared_error)
```

Отклонение на тренируемой выборке: 0.071 отклонение на тестовой выборке: 0.622

```
In [59]: rfr.result(mean_squared_error)
```

Отклонение на тренируемой выборке: 0.062 отклонение на тестовой выборке: 0.635

In [50]:
```
gbc2 = Classifier(GradientBoostingClassifier(max_features=8), data_X_train,
                  data_y_train, data_X_test, data_y_test)
gbc2.training()
gbc2.result(mean_squared_error)
```

Отклонение на тренируемой выборке: 0.607 отклонение на тестовой выборке: 0.650

In [60]:
```
gbc.result(mean_squared_error)
```

Отклонение на тренируемой выборке: 0.689 отклонение на тестовой выборке: 0.701

Как можно заметить, для классификатора градиентного спуска правильный подбор гиперпараметра существеннее исправил ошибку. Однако по итогу отклонение на тестовой выборке несущественно отличается.